

برگه تقلب بسته تاییدی ورس:: وارد کردن داده ها

مشارکت در ترجمه: وحید فرجی جبه دار، رضا مظلومی



انواع داده :

توابع خوانش آر یا readr نوع هر ستون را حدس میزند و در صورتی که صحیح باشند تبدیل را انجام می دهد. اما به صورت خودکار رشته ها را به عوامل تبدیل نمی کنند.

در بخش نتیجه نوع هر ستون را مشخص می کند.

```
## Parsed with column specification:
##   cols(
##     age = col_integer(),
##     sex = col_character(),
##     earn = col_double()
## )
```

سن
متغیر عدد صحیح
جنسیت متغیر کاراکتر

numeric درآمد ترکیبی از هر دو

1. از **problems()** برای شناسایی مساله استفاده کنید

x <- read_csv("file.csv"); problems(x)

2. از **col_** function برای هدایت تجزیه و تقسیم استفاده کنید

- **col_guess()** - the default
- **col_character()**
- **col_double()**, **col_euro_double()**
- **col_datetime**(format = "") Also **col_date**(format = ""), **col_time**(format = "")
- **col_factor**(levels, ordered = FALSE)
- **col_integer()**
- **col_logical()**
- **col_number()**, **col_numeric()**
- **col_skip()**

x <- read_csv("file.csv", col_types = cols(A = col_double(), B = col_logical(), C = col_factor()))

3. در غیر این صورت مشخصه بردار را میخواند سپس با **parse_** function. آن را تجزیه می کند.

- **parse_guess()**
- **parse_character()**
- **parse_datetime()** Also **parse_date()** and **parse_time()**
- **parse_double()**
- **parse_factor()**
- **parse_integer()**
- **parse_logical()**
- **parse_number()**

x\$A <- parse_number(x\$A)

بسته تاییدی ورس R بر اساس نسخه تاییدی دیتا ایجاد شده که در تیبلز (tibbles) ذخیره می شوند و چارچوب های داده را بهبود می دهد.



صفحه اول این برگه به شما نشان می دهد که چگونه متن ها در نرم افزار R با استفاده از بسته readr خوانده می شوند.



در صفحه دوم نحوه ایجاد نوارها با کمک tibble و چارچوب مرتب سازی داده با tider نشان داده می شود

انواع دیگر داده :

واز بسته های زیر برای وارد کردن سایر فایل ها می توانید استفاده کنید:

- **haven** - SPSS, Stata, and SAS files
- **readxl** - excel files (.xls and .xlsx)
- **DBI** - databases
- **jsonlite** - json
- **xml2** - XML
- **httr** - Web APIs
- **rvest** - HTML (Web Scraping)

ذخیره داده :

برای ذخیره کردن فایل در مسیر با فرمت ایکس می توانید از دستوره های زیر استفاده کنید:

کاما جدا کننده فایل:

write_csv(x, path, na = "NA", append = FALSE, col_names = !append)

فایل با جدا کننده دلخواه:

write_delim(x, path, delim = " ", na = "NA", append = FALSE, col_names = !append)

CSV برای اکسل

write_excel_csv(x, path, na = "NA", append = FALSE, col_names = !append)

رشته به فایل:

write_file(x, path, append = FALSE)

بردار رشته به فایل، یک عضو در هر خط

write_lines(x,path, na = "NA", append = FALSE)

شی به فایل RDS

write_rds(x, path, compress = c("none", "gz", "bz2", "xz"), ...)

تب جدا کننده فایلها:

write_tsv(x, path, na = "NA", append = FALSE, col_names = !append)

```
read_(file, col_names = TRUE, col_types = NULL, locale = default_locale(), na = c("", "NA"), quoted_na = TRUE, comment = "", trim_ws = TRUE, skip = 0, n_max = Inf, guess_max = min(1000, n_max), progress = interactive())
```

کاما جدا کننده فایل:

read_csv("file.csv")

To make file.csv run:

write_file(x = "a,b,c\n1,2,3\n4,5,NA", path = "file.csv")

جدا کننده فایل توسط نقطه ویرگول

read_csv2("file2.csv")

write_file(x = "a;b;c\n1;2;3\n4;5;NA", path = "file2.csv")

فایل به همراه نوع جدا کننده

read_delim("file.txt", delim = "|")

write_file(x = "a|b|c\n1|2|3\n4|5|NA", path = "file.txt")

فایل با عرض ثابت

read_fwf("file.fwf", col_positions = c(1, 3, 5))

write_file(x = "a b c\n1 2 3\n4 5 NA", path = "file.fwf")

تب جدا کننده فایل:

read_tsv("file.tsv") Also **read_table()**.

write_file(x = "a\tb\tc\n1\t2\t3\n4\t5\tNA", path = "file.tsv")

گزاره های کاربردی

فایل نمونه:

write_file("a,b,c\n1,2,3\n4,5,NA","file.csv")

f <- "file.csv"

خطوط پرش

read_csv(f, skip = 1)

خوانش از زیرمجموعه

read_csv(f, n_max = 1)

داده های گمشده

read_csv(f, na = c("1", ""))

بدون سر برگ

read_csv(f, col_names = FALSE)

سرصفحه ارائه دهنده

read_csv(f, col_names = c("x", "y", "z"))

خواندن داده غیر جدولی

خواندن فایل در یک رشته

read_file(file, locale = default_locale())

خواندن هر خط درون رشته خودش

read_lines(file, skip = 0, n_max = -1L, na = character(), locale = default_locale(), progress = interactive())

آپاچی با استفاده از فرمت لاگ زیر فایل را می خواند

read_log(file, col_names = FALSE, col_types = NULL, skip = 0, n_max = -1, progress = interactive())

خواندن فایل درون بردار سطری

read_file_raw(file)

خواندن هر خط در بردار سطری

read_lines_raw(file, skip = 0, n_max = -1L, progress = interactive())

چارچوب داده پیشرفته: Tibble



بسته Tibble نوع S3 جدیدی را برای ذخیره داده های تابلویی ایجاد می کند. Tibble نوع چارچوب داده را از بین می برد اما 3 رفتار را بهبود می بخشد:

زیرمجموعه: [همیشه به یک مضمون جدید برمی گرداند،] و \$ همیشه به یک بردار برمی گرداند. عدم تطبیق جزئی: باید از نام کل ستون زمانی که زیرمجموعه می دهید استفاده می کنید. نمایش دادن- زمانی که از یک Tibble پرینت میگیرید، R نمای مختصری از داده که متناسب با یک صفحه است فراهم می کند.

```
# A tibble: 234 × 6
1   <chr>   <chr> <dbl>
3     audi    a4  2.0
4     audi    a4  2.0
6     audi    a4  2.8
7     audi    a4  3.1
9     audi    a4 quattro 1.8
# ... with 224 more rows, and 3
#   cyl <int>, trans <chr>
```

tibble نمایش

```
156 1999    6 auto(l4)
158 2008    6 auto(l4)
160 1999    4 manual(m5)
161 1999    4 auto(l4)
163 2008    4 manual(m5)
165 2008    4 auto(l4)
[ reached getOption("max.print")
-- omitted 68 rows ]
```


نمایش یک جدول بزرگ

مشارکت در ترجمه: وحید فرجی جبه دار، رضا مظلومی

مرتب کردن داده ها به وسیله tidy


مرتب کردن دادها روشی برای سازماندهی داده های جدولی است. این یک ساختار داده ثابت را در بین بسته ها فراهم می کند.

یک جدول مرتب است اگر:




هر متغیر در ستون مربوط به خودش باشد


&



هر مشاهده یا مورد در ستون مربوط به خودش باشد




دسترسی به متغیرها



نمونه ها در طول عملیات برداری حفظ می شود

تقسیم سلول ها

از این توابع برای تقسیم یا ترکیب سلولها به مقادیر جدا شده جداگانه استفاده میکنیم.



separate(data, col, into, sep = "[^[:alnum:]]+", remove = TRUE, convert = FALSE, extra = "warn", fill = "warn", ...)

برای ساختن چندین ستون ، هر سلول را در یک ستون جدا میکنند.

table3		
country	year	rate
A	1999	0.7K/19M
A	2000	2K/20M
B	1999	37K/172M
B	2000	80K/174M
C	1999	212K/1T
C	2000	213K/1T

country	year	cases	pop
A	1999	0.7K	19M
A	2000	2K	20M
B	1999	37K	172
B	2000	80K	174
C	1999	212K	1T
C	2000	213K	1T

separate(table3, rate, sep = "/", into = c("cases", "pop"))

separate_rows(data, ..., sep = "[^[:alnum:]]+", convert = FALSE)

برای ساختن چندین سطر ، هر سلول را در یک ستون جدا کنید

table3					
country	year	rate	country	year	rate
A	1999	0.7K/19M	A	1999	0.7K
A	2000	2K/20M	A	1999	19M
B	1999	37K/172M	A	2000	2K
B	2000	80K/174M	A	2000	20M
C	1999	212K/1T	B	1999	37K
C	2000	213K/1T	B	1999	172M
			B	2000	80K
			B	2000	174M
			C	1999	212K
			C	1999	1T
			C	2000	213K
			C	2000	1T

separate_rows(table3, rate, sep = "/")

unite(data, col, ..., sep = "_", remove = TRUE)

چند ستون را به یک ستون ادغام می کند

table5

country	century	year	country	year
Afghan	19	99	Afghan	1999
Afghan	20	00	Afghan	2000
Brazil	19	99	Brazil	1999
Brazil	20	00	Brazil	2000
China	19	99	China	1999
China	20	00	China	2000

unite(table5, century, year, col = "year", sep = "")

تغییر شکل داده- تغییر طرح و چیدمان متغیرها در جدول

از **gather()** و **spread()** برای شناسایی مقادیر جدول به یک طرح جدید استفاده کرد.

gather(data, key, value, ..., na.rm = FALSE, convert = FALSE, factor_key = FALSE)

gather() اسامی ستون ها را به سمت ستون های کلیدی جابجا خواهد کرد، جمع آوری ارزش های هریک از ستون ها به یک ستون را انجام می دهد.

table4a					
country	1999	2000	country	year	cases
A	0.7K	2K	A	1999	0.7K
B	37K	80K	B	1999	37K
C	212K	213K	C	1999	212K
			A	2000	2K
			B	2000	80K
			C	2000	213K

کلید ارزش

gather(table4a, `1999`, `2000`, key = "year", value = "cases")

spread(data, key, value, fill = NA, convert = FALSE, drop = TRUE, sep = NULL)

spread() متغیر یکتایی از ستون کلیدی را به اسامی ستون های جابجای می کند ، مقادیر ارزش یک ستون را در ستونهای جدید پخش می کند

				→				
					country	year	cases	pop
A	1999	cases	0.7K		A	1999	0.7K	19M
A	1999	pop	19M		A	2000	2K	20M
A	200	cases	2K		B	1999	37K	172M
A	2000	pop	20M		B	2000	80K	174M
B	1999	cases	37K		C	1999	212K	1T
B	1999	pop	172M		C	2000	213K	1T
B	2000	cases	80K					
B	2000	pop	174M					
C	1999	cases	212K					
C	1999	pop	1T					
C	2000	cases	213K					
C	2000	pop	1T					

کلید ارزش

spread(table2, type, count)

مقادیر گمشده را کنترل کنید

drop_na(data, ...)

مقادیر ناموجود در ستون ها را شناسایی می کند

x	
x1	x2
A	1
B	NA
C	NA
D	3
E	NA

drop_na(x, x2)

fill(data, ..., direction = c("down", "up"))

مقادیر خالی را در ستون ها را با استفاده از الگوی مقادیر کامل می کند.

x	
x1	x2
A	1
B	NA
C	1
D	3
E	NA

fill(x, x2)

replace_na(data,

replace = list(), ...)

جایگزینی مقادیر خالی با ستون ها.

x1	x2
A	1
B	NA
C	2
D	3
E	NA

replace_na(x, list(x2 = 2))

جداول صفحه گسترده: به سرعت جداول با ترکیبی از مقادیر ایجاد کنید

complete(data, ..., fill = list())

به داده های ترکیبی از دست رفته ارزش های متغیر لیست شده را اضافه می کند.

complete(mtcars, cyl, gear, carb)

expand(data, ...)

Tibble جدیدی از تمامی ترکیبات ارزش های متغیرهای لیست شده را ایجاد می کند.

expand(mtcars, cyl, gear, carb)