

Імпорт даних : : ШПАРГАЛКА

У R **tidyverse** побудована навколо **охайних даних**, що зберігаються в **tibble** (розвиток data frame).



На лицьовій сторінці описано, як зчитувати текстові файли в R за допомогою **readr**.



На зворотній сторінці описано, як створювати tibble з **tibble** і охайні дані з **tidyr**.

ІНШІ ТИПИ ДАНИХ

Використовуйте наступні пакети для імпорту файлів іншого типу

- **haven** - файли SPSS, Stata та SAS
- **readxl** - excel файли (.xls та .xlsx)
- **DBI** - бази даних
- **jsonlite** - json
- **xml2** - XML
- **httr** - Web API
- **rvest** - HTML (дані з Інтернету)

Збереження даних

Зберігайте **x**, об'єкт R, у **path**, шлях до файлу, за допомогою:

Файл, розділений комами

write_csv(x, path, na = "NA", append = FALSE, col_names = !append)

Файл із довільним роздільником

write_delim(x, path, delim = " ", na = "NA", append = FALSE, col_names = !append)

CSV для excel

write_excel_csv(x, path, na = "NA", append = FALSE, col_names = !append)

Рядок у файл

write_file(x, path, append = FALSE)

Рядковий вектор у файл, один елемент на рядок

write_lines(x, path, na = "NA", append = FALSE)

Об'єкт у файл RDS

write_rds(x, path, compress = c("none", "gz", "bz2", "xz"), ...)

Файл, розділений табуляціями

write_tsv(x, path, na = "NA", append = FALSE, col_names = !append)

Зчитування табличних даних

Ці функції мають спільні аргументи:

read_*(file, col_names = TRUE, col_types = NULL, locale = default_locale(), na = c("", "NA"), quoted_na = TRUE, comment = "", trim_ws = TRUE, skip = 0, n_max = Inf, guess_max = min(1000, n_max), progress = interactive())

a,b,c
1,2,3
4,5,NA

A	B	C
1	2	3
4	5	NA

Файли, розділені комами

read_csv("file.csv")

Для создания file.csv исполните:

write_file(x = "a,b,c\n1,2,3\n4,5,NA", path = "file.csv")

a;b;c
1;2;3
4;5;NA

A	B	C
1	2	3
4	5	NA

Файли, розділені крапками з комами

read_csv2("file2.csv")

write_file(x = "a;b;c\n1;2;3\n4;5;NA", path = "file2.csv")

alblc
1I2I3
4I5I NA

A	B	C
1	2	3
4	5	NA

Файли з довільним роздільником

read_delim("file.txt", delim = "|")

write_file(x = "alblc\n1I2I3\n4I5I NA", path = "file.txt")

a b c
1 2 3
4 5 NA

A	B	C
1	2	3
4	5	NA

Файли з фіксованою шириною

read_fwf("file.fwf", col_positions = c(1, 3, 5))

write_file(x = "a b c\n1 2 3\n4 5 NA", path = "file.fwf")

Файли, розділені табуляціями

read_tsv("file.tsv") Також **read_table()**.

write_file(x = "a\tb\tc\n1\t2\t3\n4\t5\tNA", path = "file.tsv")

КОРИСНІ АРГУМЕНТИ

a,b,c
1,2,3
4,5,NA

Файл для зразків

write_file("a,b,c\n1,2,3\n4,5,NA", "file.csv")
f <- "file.csv"

1	2	3
4	5	NA

Пропуск рядків

read_csv(f, skip = 1)

A	B	C
1	2	3
4	5	NA

Без заголовка

read_csv(f, col_names = FALSE)

A	B	C
1	2	3

Зчитування частини

read_csv(f, n_max = 1)

x	y	z
A	B	C
1	2	3
4	5	NA

Із зазначенням заголовка

read_csv(f, col_names = c("x", "y", "z"))

A	B	C
NA	2	3
4	5	NA

Відсутні значення

read_csv(f, na = c("1", "."))

Зчитування нетабличних даних

Зчитування файлу в один рядок

read_file(file, locale = default_locale())

Зчитування рядків файлу в окремі рядки

read_lines(file, skip = 0, n_max = -1L, na = character(), locale = default_locale(), progress = interactive())

Зчитування логових файлів Apache

read_log(file, col_names = FALSE, col_types = NULL, skip = 0, n_max = -1, progress = interactive())

Зчитування файлу в raw вектор

read_file_raw(file)

Зчитування рядків файлу в raw вектори

read_lines_raw(file, skip = 0, n_max = -1L, progress = interactive())



Типи даних

Функції readr вгадують типи стовпчиків і конвертують їх, коли доречно (але НІКОЛИ рядки в фактори автоматично). Повідомлення описує типи стовпчиків у результаті.

```
## Parsed with column specification:
## cols(
##   age = col_integer(),
##   sex = col_character(),
##   earn = col_double()
## )
```

age -
ціле
число

earn - число double

sex -
рядок

1. Використовуйте **problems()** для діагностики проблем

x <- read_csv("file.csv"); problems(x)

2. Викорис. col_ функцію для розбору

- **col_guess()** - за замовчуванням
- **col_character()**
- **col_double()**, **col_euro_double()**
- **col_datetime(format = "")** Також **col_date(format = "")**, **col_time(format = "")**
- **col_factor(levels, ordered = FALSE)**
- **col_integer()**
- **col_logical()**
- **col_number()**, **col_numeric()**
- **col_skip()**

x <- read_csv("file.csv", col_types = cols(A = col_double(), B = col_logical(), C = col_factor()))

3. По-іншому: зчитуйте як рядкові вектори і розбирайте з parse_ функцією

- **parse_guess()**
- **parse_character()**
- **parse_datetime()** Також **parse_date()** та **parse_time()**
- **parse_double()**
- **parse_factor()**
- **parse_integer()**
- **parse_logical()**
- **parse_number()**

x\$A <- parse_number(x\$A)




Tibble - розвиток data frame

Пакет **tibble** вводить новий S3 клас для зберігання табличних даних, **tibble**. Tibble успадковує клас **data frame**, але покращує три напрямки:



- **Вибір елементів** - [завжди повертає новий **tibble**, [[та \$ - вектор.
- **Немає часткового узгодження** - Ви повинні використовувати повні імена стовпчиків при виборі елементів.
- **Відображення** - При друку **tibble**, R виводить короткий вид даних, що уміщається на один екран.



```
# A tibble: 234 x 6
  manufacturer <chr> model <chr> displ <dbl>
1 audi a4 1.8 1.8
2 audi a4 2.0 2.0
3 audi a4 2.0 2.0
4 audi a4 2.0 2.0
5 audi a4 2.0 2.0
6 audi a4 2.0 2.0
7 audi a4 2.0 2.0
8 audi a4 2.0 2.0
9 audi a4 2.0 2.0
10 audi a4 2.0 2.0
... with 224 more rows, and 3
more variables: year <int>,
cyl <int>, trans <chr>
```

вигляд tibble

```
156 1999 6 auto(l4)
157 1999 6 auto(l4)
158 2008 6 auto(l4)
159 2008 8 auto(s4)
160 1999 4 manual(m5)
161 1999 4 auto(l4)
162 2008 4 manual(m5)
163 2008 4 manual(m5)
164 2008 4 auto(l4)
165 2008 4 auto(l4)
166 1999 4 auto(l4)
# reached getOption("max.print")
# omitted 68 rows ]
```

вигляд data frame

- Контроль виглядом за замовч. опціями:
options(tibble.print_max = n, tibble.print_min = m, tibble.width = Inf)
- Перегляд повних даних: **View()** або **glimpse()**
- Повернення до data frame: **as.data.frame()**

СТВОРЕННЯ TIBBLE ДВОМА СПОСОБАМИ

tibble(...)
Створює по стовпчикам.

tibble(x = 1:3, y = c("a", "b", "c"))

Обидва роблять цей tibble

tribble(...)
Створює по рядкам.

**tribble(~x, ~y,
1, "a",
2, "b",
3, "c")**

```
A tibble: 3 x 2
  x     y
<int> <chr>
1     1 a
2     2 b
3     3 c
```

as_tibble(x, ...)

Конвертує data frame у tibble.

enframe(x, name = "name", value = "value")

Конвертує іменованний вектор в tibble


is_tibble(x) Перевіряє, чи є x tibble.




Охайні дані з tidyr

Охайні дані - це спосіб організації табличних даних. Це встановлює структуру даних, узгоджену між пакетами.

Таблиця охайна, якщо:



Кожна змінна - стовпчик




Кожне спостереження - рядок

В охайних даних:



Легко звертатися до змінних, як до векторів



Зберіг. спостереження при векторизованих операціях

Форматування даних - зміна розташування елементів в таблиці

Використовуйте **gather()** та **spread()** для реорганізації елементів таблиці.

gather(data, key, value, ..., na.rm = FALSE, convert = FALSE, factor_key = FALSE)
spread(data, key, value, fill = NA, convert = FALSE, drop = TRUE, sep = NULL)

Переміщує імена стовпчиків в стовпчик **key**, збираючи значення стовпчиків в спільний стовпчик **value**.

table4a

country	1999	2000
A	0.7K	2K
B	37K	80K
C	212K	213K



country	year	cases
A	1999	0.7K
B	1999	37K
C	1999	212K
A	2000	2K
B	2000	80K
C	2000	213K

key value

**gather(table4a, `1999`, `2000`,
key = "year", value = "cases")**

table2

country	year	type	count
A	1999	cases	0.7K
A	1999	pop	19M
A	2000	cases	2K
A	2000	pop	20M
B	1999	cases	37K
B	1999	pop	172M
B	2000	cases	80K
B	2000	pop	174M
C	1999	cases	212K
C	1999	pop	1T
C	2000	cases	213K
C	2000	pop	1T

key value

spread(table2, type, count)

country	year	cases	pop
A	1999	0.7K	19M
A	2000	2K	20M
B	1999	37K	172M
B	2000	80K	174M
C	1999	212K	1T
C	2000	213K	1T

Робота с відсутніми значеннями

drop_na(data, ...)

Прибирає рядки з NA у стовпчиках з ...

x1	x2
A	1
B	NA
C	NA
D	3
E	NA

drop_na(x, x2)

fill(data, ..., .direction = c("down", "up"))

Замінює NA у стовпчиках з ... крайніми не-NA значеннями.

x1	x2
A	1
B	NA
C	NA
D	3
E	NA

fill(x, x2)

replace_na(data, replace = list(), ...)

Замінює NA по стовпчиках.

x1	x2
A	1
B	NA
C	NA
D	3
E	NA

replace_na(x, list(x2 = 2))

Розширення таблиць - швидке створення таблиць з комб-ми значень

complete(data, ..., fill = list())

Додає до даних відсутні комбінації значень змінних з ...


complete(mtcars, cyl, gear, carb)

expand(data, ...)

Створює новий tibble з усіма комбінаціями значень змінних з ...

expand(mtcars, cyl, gear, carb)

Поділ клітинок



Функції для поділу або комбінування клітинок в окремі значення.

separate(data, col, into, sep = "[^:alnum:]", remove = TRUE, convert = FALSE, extra = "warn", fill = "warn", ...)

Поділяє клітинки стовпчика по окремих стовпчиках.

table3

country	year	rate
A	1999	0.7K/19M
A	2000	2K/20M
B	1999	37K/172M
B	2000	80K/174M
C	1999	212K/1T
C	2000	213K/1T



country	year	cases	pop
A	1999	0.7K	19M
A	2000	2K	20M
B	1999	37K	172
B	2000	80K	174
C	1999	212K	1T
C	2000	213K	1T

**separate(table3, rate,
into = c("cases", "pop"))**

separate_rows(data, ..., sep = "[^:alnum:].+", convert = FALSE)

Поділяє клітинки стовпчика по окремих рядках. Також **separate_rows_()**.

table3

country	year	rate
A	1999	0.7K/19M
A	2000	2K/20M
B	1999	37K/172M
B	2000	80K/174M
C	1999	212K/1T
C	2000	213K/1T



country	year	rate
A	1999	0.7K
A	1999	19M
A	2000	2K
A	2000	20M
B	1999	37K
B	1999	172M
B	2000	80K
B	2000	174M
C	1999	212K
C	1999	1T
C	2000	213K
C	2000	1T

separate_rows(table3, rate)

unite(data, col, ..., sep = "_", remove = TRUE)

Об'єднує клітинки кількох стовпчиків в один стовпчик.

table5

country	century	year
Afghan	19	99
Afghan	20	0
Brazil	19	99
Brazil	20	0
China	19	99
China	20	0



country	year
Afghan	1999
Afghan	2000
Brazil	1999
Brazil	2000
China	1999
China	2000

**unite(table5, century, year,
col = "year", sep = "")**