


# Transformação de dados com data.table :: CHEAT SHEET



## Informação básica

“data.table” é um pacote extremamente rápido e de uso eficiente de memória usado na transformação de dados em R. Ele funciona por converter o conjunto de dados nativo do R (data.frame) em data.table que apresenta funcionalidades novas e melhoradas. O uso básico de data.tables segue:

**dt[i, j, by]**

pegue data.table **dt**,  
subdivida linhas usando **i**  
e manipule colunas por **j**,  
agrupadas de acordo com **by**

data.tables também são data.frames, portanto funções que se aplicam a data.frames também funcionam sobre data.tables


## Crie um data.table

**data.table(a = c(1, 2), b = c("a", "b"))**  
cria um data.table a partir do zero. Análogo ao data.frame().

**setDT(df)\*** ou **as.data.table(df)**  
converte um data.frame ou lista a um data.table.

## Subdivida linhas usando i

 **dt[1:2, ]**  
subdivide linhas baseado nos números (índices) das linhas.

 **dt[a > 5, ]**  
subdivide linhas baseado em valores em uma ou mais colunas.


### OPERADORES LÓGICOS PARA USAR EM i

|   |    |          |      |   |           |
|---|----|----------|------|---|-----------|
| < | <= | is.na()  | %in% |   | %like%    |
| > | >= | !is.na() | !    | & | %between% |


## Manipule colunas por j

### EXTRAIR

 **dt[, c(2)]**  
extraí colunas por número; anteceda números de colunas com “-” para remover colunas.


 **dt[, .(b, c)]**  
extraí colunas por nome.


### SUMARIZAR


 **dt[, .(x = sum(a))]**  
cria um data.table com novas colunas baseado no valores sumarizados das linhas.

funções de sumário como mean(), median(), min(), max(), etc. podem ser usadas para sumarizar linhas


### COMPUTAR COLUNAS\*

 **dt[, c := 1 + 2]**  
calcula e cria uma coluna baseado numa expressão


 **dt[a == 1, c := 1 + 2]**  
computa uma coluna baseado numa expressão, mas apenas para um grupo de linhas

 **dt[, `:=`(c = 1, d = 2)]**  
computa múltiplas colunas baseado em diferentes expressões


### DELETAR COLUNAS

 **dt[, c := NULL]**  
remove uma coluna.

### CONVERTER TIPOS DE COLUNAS

 **dt[, b := as.integer(b)]**  
converte o tipo de coluna usando as.integer(), as.numeric(), as.character(), as.Date(), etc..

## Agrupe de acordo com by

 **dt[, j, by = .(a)]** – agrupa linhas por valores em colunas específicas.

**dt[, j, keyby = .(a)]** – agrupa e simultaneamente e ordena linhas por valores em colunas específicas.

### OPERAÇÕES AGRUPADAS COMUNS

**dt[, .(c = sum(b)), by = a]** – sumariza linhas dentro de grupos.

**dt[, c := sum(b), by = a]** – cria uma nova coluna e computa linhas dentro de grupos.

**dt[, .SD[1], by = a]** – extraí primeira linha de grupos.


**dt[, .SD[N], by = a]** – extraí ultima linha de grupos.

## Encadeamento

**dt[...][...]** – realiza sequência de operações em data.table por encadeamento de múltiplos “[ ]”.


## Funções para data.tables

### REORDENAR

 **setorder(dt, a, -b)**  
reordena um data.table de acordo com colunas especificadas; anteceda nomes de colunas com “-” para ordens decrescentes.

### \* SET FUNCTIONS AND :=

funções em data.table prefixadas com “set” e o operador “:=” funcionam sem “<-” para alterar os dados sem fazer cópias na memória. Por exemplo, o mais eficiente “setDT(df)” é análogo a “df <- as.data.table(df)”.



## LINHAS ÚNICAS

| a | b |
|---|---|
| 1 | 2 |
| 2 | 2 |
| 1 | 2 |

**unique**(dt, by = c("a", "b")) – extrai linhas únicas baseado em colunas especificadas por “by”. Omita “by” para usar todas as colunas.

**uniqueN**(dt, by = c("a", "b")) – conta o número de linhas únicas baseado em colunas especificadas por “by”.

## RENOMEAR COLUNAS

| a | b |
|---|---|
| 1 | 2 |
| 2 | 2 |
| 1 | 2 |

**setnames**(dt, c("a", "b"), c("x", "y"))  
renomeia colunas.

## DEFINA PALAVRAS-CHAVE

**setkey**(dt, a, b) – define palavras-chave que permitem pesquisa rápida e repetida em colunas especificadas usando "dt[(valor),]" ou fundir dados sem especificar colunas usando "dt\_a[dt\_b]".

# Combinar data.tables

## JUNTAR (join)

| a | b |
|---|---|
| 1 | c |
| 2 | a |
| 3 | b |

**dt\_a[dt\_b, on = .(b = y)]** – junte data.tables em linhas com valores iguais

| a | b | c |
|---|---|---|
| 1 | c | 7 |
| 2 | a | 5 |
| 3 | b | 6 |

**dt\_a[dt\_b, on = .(b = y, c > z)]** – junte data.tables em linhas com valores iguais e desiguais

## JUNÇÃO POR “ROLAMENTO” (Rolling join)

| a | id | date       |
|---|----|------------|
| 1 | A  | 01-01-2010 |
| 2 | A  | 01-01-2012 |
| 3 | A  | 01-01-2014 |
| 1 | B  | 01-01-2010 |
| 2 | B  | 01-01-2012 |

**dt\_a[dt\_b, on = .(id = id, date = date), roll = TRUE]** – junte data.tables em linhas correspondentes a colunas de IDs, mas mantendo apenas as correspondências mais recentes com o data.table a esquerda de acordo com colunas de datas.

“roll = -Inf” reverte a direção.

## LIGAR

| a | b |
|---|---|
| 1 | 2 |
| 2 | 2 |
| 1 | 2 |

**rbind**(dt\_a, dt\_b) – combinar linhas de dois data.tables

| a | b |
|---|---|
| 1 | 2 |
| 2 | 2 |
| 1 | 2 |

**cbind**(dt\_a, dt\_b) – combinar colunas de dois data.tables

# Reformate um data.table

## TRANSFORMAR PARA FORMATO AMPLO

| id | y | a | b |
|----|---|---|---|
| A  | x | 1 | 3 |
| A  | z | 2 | 4 |
| B  | x | 1 | 3 |
| B  | z | 2 | 4 |

**dcast**(dt,  
id ~ y,  
value.var = c("a", "b"))

Transforme um data.table de um formato longo a amplo.

dt  
id ~ y  
Um data.table.  
Formula com um “LHS”: colunas de IDs contendo IDs de múltiplas entradas; e um “RHS”: colunas com valores para distribuir nos cabeçalhos das colunas.  
value.var  
Colunas contendo valores para preencher células.

## TRANSFORMAR PARA FORMATO LONGO

| id | a | x | a | z | b | x | b | z |
|----|---|---|---|---|---|---|---|---|
| A  | 1 | 2 | 3 | 4 |   |   |   |   |
| B  | 1 | 2 | 3 | 4 |   |   |   |   |

**melt**(dt,  
id.vars = c("id"),  
measure.vars = patterns("^a", "^b"),  
variable.name = "y",  
value.name = c("a", "b"))

Transforme um data.table de um formato amplo a longo.

dt  
id.vars  
measure.vars  
variable.name,  
value.name  
Um data.table.  
Colunas de IDs com IDs para múltiplas entradas.  
Colunas contendo valores para preencher em células (geralmente em forma de padrões).  
Nomes das novas colunas para variáveis e valores derivados das colunas antigas.

# Aplique funções a colunas

## APLICAR UMA FUNÇÃO A MÚLTIPLAS COLUNAS

| a | b |
|---|---|
| 1 | 4 |
| 2 | 5 |
| 3 | 6 |

**dt[, lapply(.SD, mean), .SDcols = c("a", "b")]** – aplicar uma função – e.g. mean(), as.character(), which.max() – a colunas especificadas em .SDcols com lapply() e o símbolo .SD. Também funciona com grupos.

| a | b |
|---|---|
| 1 | 2 |
| 2 | 2 |
| 3 | 2 |

**cols <- c("a")**  
**dt[, paste0(cols, "\_m") := lapply(.SD, mean), .SDcols = cols]** – aplicar uma função a colunas especificadas e assignar o resultado com variáveis sufixadas aos dados originais.

# Linhas sequenciais

## IDs DE LINHAS

| a | b |
|---|---|
| 1 | a |
| 2 | a |
| 3 | b |

**dt[, c := 1:N, by = b]** – dentro de grupos, compute uma coluna com linhas sequenciais de IDs.

## DEFASAGEM (LAG) & INCREMENTO (LEAD)

| a | b |
|---|---|
| 1 | a |
| 2 | a |
| 3 | b |
| 4 | b |
| 5 | b |

**dt[, c := shift(a, 1), by = b]** – dentro de grupos, duplicar uma coluna com linhas defasadas por um valor especificado.

**dt[, c := shift(a, 1, type = "lead"), by = b]** – dentro de grupos, duplicar uma coluna com linhas sendo incrementadas por um valor especificado.

# carregar & salvar arquivos

## IMPORTAR

**fread**("file.csv")  
carregar dados desde um arquivo plano, como \*.csv ou \*.tsv em R.  
**fread**("file.csv", select = c("a", "b"))  
carregar colunas especificadas de um arquivo plano em R.

## EXPORTAR

**fwrite**(dt, "file.csv") – salvar dados em um arquivo plano desde R.